

Analyse Comportementale Clientèle Retail

Atelier Machine Learning — E-commerce de Cadeaux

AUTEURE

Ahmed Mnif

ML

Pipeline complet

Données → Modélisation → Déploiement



Vue d'ensemble du projet


ENIS | ML 2025-2026

Pipeline de bout en bout : données, modélisation, déploiement



Données & Défis

- Dataset de 52 variables issues de transactions retail réelles.
- Qualité complexe : valeurs manquantes, formats hétérogènes, valeurs aberrantes.
- Traitement critique de l'âge ($\approx 30\%$ NaN) et des scores de satisfaction.



Pipeline ML

- Nettoyage rigoureux $\rightarrow$ Feature Engineering $\rightarrow$ Réduction ACP.
- Comparaison : Régression Logistique vs Random Forest.
- Optimisation par GridSearchCV avec focus sur le F1-Score.



Déploiement

- Application Web interactive développée avec Flask.
- Architecture modulaire avec API REST pour l'inférence en temps réel.
- Solution de bout en bout : du prétraitement à la prédiction utilisateur.

Question de cadrage : *Quel est le défi majeur du e-commerce de cadeaux (saisonnalité extrême, panier irrégulier) qui justifie l'usage intensif du Machine Learning pour la rétention ?*

Contexte & Mission

ENIS | ML 2025-2026

Marché compétitif, données riches, enjeux stratégiques



Le Marché

Secteur e-commerce de cadeaux : un environnement hautement compétitif nécessitant une analyse prédictive fine pour anticiper les besoins clients et les fenêtres d'achat.



Notre Mission

Transformer les historiques transactionnels bruts en connaissances stratégiques exploitables pour la prise de décision retail.

★ 4 372 observations × 52 variables



Personnalisation de l'offre

01

Segmentation comportementale pour adapter dynamiquement le catalogue.



Fidélisation (réduction du Churn)

02

Identification précoce des signes de désengagement pour lancer des actions de rétention.



Optimisation de la rentabilité

03

Ciblage prioritaire des segments les plus rentables pour maximiser le ROI marketing.

Trois leviers complémentaires : connaître, retenir, rentabiliser — chacun prend appui sur le même socle de données transactionnelles.

Objectifs pédagogiques du pipeline

ENIS | ML 2025-2026

Six étapes structurantes, du brut au modèle déployé



01

Exploration

Analyser la qualité, la structure et la distribution des données ; identifier anomalies et valeurs manquantes.



02

Préparation


Maîtriser le nettoyage, l'imputation, l'encodage catégoriel et la normalisation statistique.



03

Transformation

Réduire la dimensionnalité par Analyse en Composantes Principales (ACP) pour simplifier les modèles.



04

Modélisation

Implémenter Régression Logistique, Random Forest, clustering et régression.



05

Évaluation

Interpréter Accuracy, Precision, Recall, F1-Score et courbes ROC-AUC.



06

Déploiement

Concevoir une interface utilisateur Flask pour rendre le modèle accessible en production.

Environnement & Structure du projet

Stack technique et architecture modulaire

ENIS | ML 2025-2026



Outils de développement

- **VS Code** IDE principal
- **Git / GitHub** Versioning
- **Python 3.x (venv)** Runtime isolé
- **Flask** Framework Web



Bibliothèques principales

pandas

numpy

scikit-learn

imbalanced-learn

joblib

matplotlib

seaborn

optuna

flask

scipy



Architecture modulaire

📁 **root /**

📁 **app/** *(Flask API & UI)*

📁 **data/** *(Raw & Processed)*

📁 **models/** *(Artifacts .pkl)*

📁 **src/** *(Scripts Python)*

└ preprocessing.py

└ train_model.py

└ predict.py

📁 **reports/** *(Visualisations)*

📄 **run.py** *(Entry point)*

Le jeu de données : 52 variables comportementales

ENIS | ML 2025-2026

Cible binaire + 51 features transactionnelles, comportementales et catégorielles



Variable cible : Churn (feature n° 34)

Variable binaire : **0** = Client fidèle / **1** = Client parti (attrition)



TRANSACTIONNELLES

Features 1 – 17

- Indicateurs RFM : Recency, Frequency, Monetary (Total/Avg/Std).
- Quantité totale commandée et ancienneté client (Tenure).
- Saisonnalité : jour, heure et mois d'achat préférés.



COMPORTEMENTALES

Features 18 – 34

- Ratios d'activité : WeekendRatio, ReturnRatio, annulations.
- Engagement : délai moyen entre achats, produits uniques.
- Satisfaction : score de satisfaction et tickets support.



CATÉGORIELLES

Features 35 – 52

- Profils : segment RFM (4), catégorie d'âge (7), genre (3).
- Type de client (5) et catégorie de dépense (4).
- Géographie : région (8) et pays (37+ localisations).

Exploration des données (EDA)

Structure, qualité, anomalies et déséquilibre de la cible

STRUCTURE & QUALITÉ


- **4 372 observations** et 52 variables (types mixtes : int64, float64, object).
- **Âge** : 1 311 valeurs manquantes ($\approx 30\%$), nécessitant une imputation robuste.
- **Multicolinéarité** : corrélation quasi-parfaite ($r \approx 1$) entre MonetaryTotal et MonetaryAvg.

ANOMALIES CRITIQUES

- **TotalQuantity** : présence de valeurs négatives (jusqu'à -303) liées aux retours.
- **SatisfactionScore** : valeurs hors échelle $\{-1, 0, 99\}$ détectées.
- **SupportTickets** : outliers extrêmes (valeur 999) identifiés.

VARIABLE CIBLE : CHURN

66.7% Fidèles | **33.3%** Partis



Constat

Le déséquilibre modéré (ratio 2:1) justifie l'utilisation future de techniques de rééquilibrage comme **SMOTE**.

Pipeline de prétraitement — 11 étapes

De la donnée brute au dataset modélisable

ÉTAPE	ACTION & MÉTHODE	IMPACT SUR LE DATASET
1–2	Suppression (data leakage & variables inutiles)	52 → 48 colonnes
3	Imputation médiane de la variable Age	1 311 NaN éliminés
4	Imputation constante (AvgDaysBetween)	79 NaN éliminés
5	Correction des outliers (Satisfaction, SupportTickets)	Plages valides [1-5] et [0-8]
6	Parsing de RegistrationDate	+4 features temporelles
7	Feature Engineering (LastLoginIP → Is_Private_IP)	Donnée brute exploitable
8	Feature Engineering RFM (indicateurs avancés)	+3 indicateurs comportementaux
9	One-Hot Encoding (27 colonnes catégorielles)	51 → 112 colonnes binaires
10	Split Train/Test stratifié 80/20	3 497 / 875 observations
11	SMOTE (sur l'ensemble d'entraînement uniquement)	3 497 → 4 668 obs. (50/50)

Feature Engineering & encodage des variables

ENIS | ML 2025-2026

Nouvelles variables RFM, encodage one-hot et réduction dimensionnelle

Indicateurs RFM construits

MonetaryPerDay = **MonetaryTotal** / (**Recency** + 1)

→ Intensité de dépense récente

AvgBasketValue = **MonetaryTotal** / **Frequency**

→ Valeur moyenne par achat

TenureRatio = **Recency** / **CustomerTenureDays**

→ Indicateur de désengagement

Features dérivées supplémentaires

Is_Private_IP — binaire extrait de LastLoginIP

RegYear, RegMonth, RegDay, RegWeekday

— depuis RegistrationDate (+4 colonnes)

Encodage One-Hot

Variables nominales (Gender, Region, CustomerType...) → colonnes binaires.
drop_first=True pour éviter le dummy variable trap.

27 cat.

51 → 112 cols

+61 binaires

Normalisation — StandardScaler

$$z = (x - \mu) / \sigma \quad \rightarrow \quad E[z] = 0, \quad \text{Var}(z) = 1$$

Centrage-réduction de toutes les features numériques pour homogénéiser les échelles.

Réduction dimensionnelle — ACP

112

Features initiales



ACP

Composantes orthogonales



≥ 95%

Variance expliquée

Simplification du modèle, élimination de la multicolinéarité, réduction du bruit.

Séparation des données & rééquilibrage (SMOTE)

Split stratifié 80/20 et oversampling synthétique anti-leakage

Split stratifié 80/20


Répartition proportionnelle des classes (stratify=y) pour éviter tout biais.

X_train (entraînement)	3 497 obs.
X_test (évaluation)	875 obs.
Total	4 372 obs.

Mécanisme SMOTE

- Génération d'exemples synthétiques par interpolation entre k-voisins.
- Équilibre parfait atteint : 50% / 50% dans le set d'entraînement.

Répartition initiale




RÈGLE D'OR : ANTI-LEAKAGE

SMOTE est appliqué **uniquement** sur le **train set**. Le **test set** conserve la distribution réelle du marché — sinon les métriques d'évaluation deviennent trompeuses.

Impact du rééquilibrage (Train)

● Fidèles (0) ● Churnés (1)



Modèle 1 — Régression logistique

Modèle linéaire interprétable, baseline robuste pour la classification

Principe mathématique

$$P(y=1|x) = \sigma(w^T x + b) = 1 / (1 + e^{-(w^T x + b)})$$

- Estimation de probabilité via la fonction sigmoïde.
- Seuil de décision fixé à 0,5 pour la classification.

Avantages majeurs

- ✓ **Interprétabilité** : coefficients directement liés à l'influence des features.
- ✓ **Efficacité** : rapidité d'entraînement et de prédiction en temps réel.
- ✓ **Probabilités** : scores calibrés, exploitables pour l'analyse de risque.

Optimisation (GridSearchCV)

Régularisation (C)

0.01, 0.1, 1, 10, 100

Solver

lbfgs, liblinear

Max iterations

100, 500, 1000

Penalty

11, 12

Validation croisée : 5-fold | Métrique cible : F1-Score

Limites & contraintes

- ⊘ Suppose une relation linéaire entre les features et le logit.
- ⊘ Performance limitée face à des interactions complexes non-linéaires.
- ⊘ Sensible à la multicolinéarité (nécessite une ACP préalable).

Modèle 2 — Random Forest Classifier

Algorithme d'ensemble par bagging d'arbres de décision



Principe de l'algorithme

Algorithme d'ensemble basé sur le **Bagging**. Il combine plusieurs arbres de décision indépendants pour réduire la variance et améliorer la précision via un **vote majoritaire**.



Forces du modèle

- ✓ Excellente gestion des relations non linéaires.
- ✓ Robuste face aux valeurs aberrantes (outliers).
- ✓ Calcul automatique de l'importance des variables.



Hyperparamètres optimisés

n_estimators	100, 200, 500	Nombre d'arbres
max_depth	5, 10, 20, None	Profondeur maximale
min_samples_split	2, 5, 10	Min échantillons pour split
max_features	sqrt, log2	Sous-ensemble de features



Limites & contraintes

- ⊘ Complexité d'interprétation (effet « boîte noire »).
- ⊘ Coût computationnel et empreinte mémoire élevés.
- ⊘ Risque de surapprentissage si la profondeur n'est pas contrôlée.

Évaluation & comparaison des modèles

Métriques de classification et choix final



Accuracy & Precision

Justesse globale et fiabilité des prédictions positives (churn détecté).



Recall (Rappel)

Capacité à identifier tous les clients à risque — métrique critique pour la rétention.



F1-Score

Moyenne harmonique entre précision et rappel, idéale pour classes déséquilibrées.



AUC-ROC


Performance globale de discrimination entre fidèles et churneurs.

Modèle	Accuracy	Precision	Recall	F1-Score	AUC
Régression Logistique	0,8869	0,7981	0,8832	0,8385	0,9504
Random Forest	0,8926	0,8774	0,7869	0,8297	0,9524



Choix du modèle : Régression Logistique

Bien que le Random Forest soit plus précis, la **Régression Logistique** est retenue car elle maximise le **Rappel (0,88 vs 0,78)**. En stratégie retail, il est plus coûteux de manquer un client prêt à partir (faux négatif) que de cibler par erreur un client fidèle.



Déploiement — Application Web Flask

ENIS | ML 2025-2026

Architecture MVC, artefacts sérialisés et API REST



Architecture MVC & Factory

- **predict.py** — Classe ChurnPredictor gérant l'inférence et le chargement du modèle.
- **routes.py** — Contrôleur gérant les endpoints HTTP et la logique API.
- **templates/** — Interface HTML5 / CSS3 responsive pour l'utilisateur final.



Artefacts sérialisés (Joblib)

- **preprocessor_pipeline.pkl** — Pipeline complet de traitement.
- **best_model.pkl** — Modèle final de Régression Logistique.
- **features_meta.pkl** — Métadonnées et types de colonnes.



Séquence de lancement

- 1 **preprocessing.py** — Nettoyage et transformation initiale.
- 2 **train_model.py** — Entraînement et sérialisation joblib.
- 3 **run.py** — Lancement du serveur Flask sur le port 5000.



API REST & interface

POST

/predict

Inférence temps réel des données JSON.

- Calcul automatique du score de probabilité et statut du risque.
- Feedback visuel immédiat : « Risque de Churn » ou « Client Fidèle ».

Conclusion générale & perspectives

Bilan, apports pédagogiques et pistes d'amélioration



Bilan du projet

- Pipeline ML complet : de la donnée brute au déploiement Flask opérationnel.
- Dataset complexe (52 features) traité par 11 étapes rigoureuses.
- Régression Logistique validée pour son équilibre Recall / F1.

PERFORMANCE FINALE

0,8385

F1-Score

0,8832

Recall

0,9504

AUC



Apports pédagogiques

- Maîtrise du cycle de vie des données en environnement réel.
- Gestion des biais (SMOTE) et de la multicolinéarité (ACP).
- Industrialisation : sérialisation, API REST et inférence temps réel.



Perspectives d'amélioration



Modèles de boosting (XGBoost, LightGBM) et réseaux de neurones.



Explicabilité via SHAP pour une aide à la décision plus transparente.



Migration vers un déploiement Cloud (Azure / AWS) pour la mise à l'échelle.

Merci pour votre attention.

Prédiction Churn — E-commerce

127.0.0.1:5000

E-commerce ML

ChurnPredict

Analyse comportementale client

Renseignez les données du client pour prédire son risque de churn.

▸ INDICATEURS RFM

Récence (jours depuis dernier achat)

45

Fréquence (nombre de commandes)

Ex: 5

▸ DONNÉES MONÉTAIRES

Montant Total (€)

Ex: 1200.50

Panier Moyen (€)

Ex: 28.50

▸ SATISFACTION & SUPPORT

Score De Satisfaction (1 à 5)

Ex: 3.5

Tickets Support (0 à 15)

Ex: 2

▸ COMPORTEMENT D'ACHAT